

Datos Extremales (2025)

MEDIA

2025-03-13

Índice general

1	La teoría asintótica clásica, las distribuciones extremales y sus dominios de atracción	5
1.1	Datos extremos	5
1.2	Las distribuciones extremales	7
1.3	Distribución Extremal Asintótica	18
1.4	Supremo esencial de una variable aleatoria o distribución	18
1.5	Distribución max-estables	20
2	Un primer enfoque de datos no <i>iid</i>	23
2.1	Análisis de series temporales	23
2.2	Pruebas de raíz unitaria y tendencia	23
3	Parts	27
4	Footnotes and citations	29
4.1	Footnotes	29
4.2	Citations	29
5	Blocks	31
5.1	Equations	31
5.2	Theorems and proofs	31
5.3	Callout blocks	31
5.4	Referencias cruzadas	32

6	Sharing your book	35
6.1	Publishing	35
6.2	404 pages	35
6.3	Metadata for sharing	35

Capítulo 1

La teoría asintótica clásica, las distribuciones extremales y sus dominios de atracción

1.1 Datos extremos

Se dice que tenemos *datos extremos* cuando cada dato corresponde al máximo o mínimo de varios registros. Ejemplos de este tipo de datos son:

- La máxima altura semanal de la ola en una plataforma marina o portuaria (m).
- La máxima velocidad de viento en determinada dirección a lo largo de un mes (km/h).
- La temperatura ambiental mínima a lo largo de un día (\dot{C}).
- La temperatura ambiental máxima a lo largo de un día (\dot{C}).
- La máxima velocidad de tráfico en un enlace de una red de datos de datos en una hora (Mb/s).
- El mayor registro en un conteo de Coliformes fecales sobre agua costeras al cabo de quince días.

Son un caso particular de evento raro o gran desviación respecto a la media. En resumen, en una gran variedad de dominios disciplinares suele ser de gran interés el trabajo con datos extremos, los que admiten diversos enfoques. Entre ellos, los propios al párrafo anterior (eventos raros, grandes desviaciones), que se verán en el curso. Sin embargo, el comienzo del curso se centra en la teoría

más clásica de estadística de datos extremos, basada en el trabajo de Fréchet, Gumbel, Weibull, Fisher, Tippet, Gnedenko, entre otros.

Observación 1: Se recuerda que si X e Y son variables aleatorias independientes, cuyas distribuciones son, respectivamente, F y G , entonces la variable

$$\max(X, Y) \quad (1.1)$$

tiene por distribución la función H definida por

$$H(t) = F(t) G(t) \quad (1.2)$$

Observación 2: En esta parte inicial del curso asumiremos que nuestros datos son *iid* (independientes e idénticamente distribuidos, son dos suposiciones juntas). Esta doble suposición suele NO ser realista en aplicaciones concretas (ninguna de sus dos componentes, incluso) pero para comenzar a entender la teoría clásica, la utilizaremos por un tiempo.

Observación 3: Resulta claramente de la Observación 1, que si tenemos datos X_1, \dots, X_n *iid* con distribución F , entonces

$$X_n^* = \max(X_1, \dots, X_n) \quad (1.3)$$

tiene distribución F_n^* dada por

$$F_n^*(t) = F(t)^n \quad (1.4)$$

Si conocemos la distribución F conoceríamos la distribución F_n^* , pero en algunos casos la lectura que queda registrada es la del dato máximo y no la de cada observación que dio lugar al mismo, por lo que a veces ni siquiera es viable estimar F . Pero aún en los casos en que F es conocida o estimable, si n es grande, la fórmula de F_n^* puede resultar prácticamente inmanejable. En una línea de trabajo similar a la que aporta el *Teorema Central del Límite* en la estadística de valores medios, un teorema nos va a permitir aproximar F_n^* por distribuciones más sencillas. Este es el *Teorema de Fischer-Tippet-Gnedenko* (FTG) que presentaremos en breve.

Observación 4: Si X_1, \dots, X_n es *iid* y definimos $Y_i = -X_i$ para todo valor de i , entonces Y_1, \dots, Y_n es *iid* y además

$$\min(X_1, \dots, X_n) = -\max(Y_1, \dots, Y_n) \quad (1.5)$$

la teoría asintótica de los mínimos de datos *iid* se reduce a la de los máximos, razón por la que nos concentramos aquí en estudiar el comportamiento asintótico de los **máximos** exclusivamente.

1.2 Las distribuciones extremales

Las distribuciones extremales son tres: la *distribución de Gumbel*, la *distribución de Weibull* y la *distribución de Fréchet*. En su versión *standard* o *típica* se definen del modo siguiente.

Se dice que una variable tiene distribución de:

-**Gumbel** si su distribución es

$$\Lambda(x) = e^{\{-e^{-x}\}} \quad \text{para todo } x \text{ real.}$$

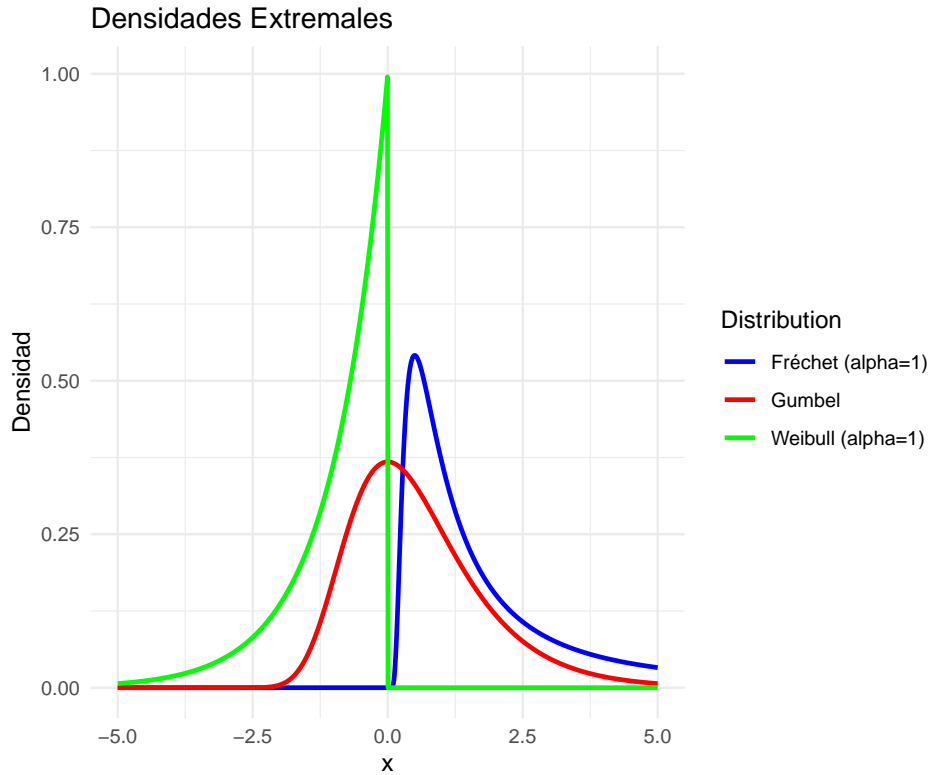
-**Weibull** de orden $\alpha > 0$ si su distribución es

$$\Psi_{\alpha}(x) = \begin{cases} e^{\{-(-x)^{\alpha}\}} & \text{si } x < 0 \\ 1 & \text{en otro caso} \end{cases}$$

-**Fréchet** de orden $\alpha > 0$ si su distribución es

$$\Phi_{\alpha}(x) = \begin{cases} e^{\{-x^{-\alpha}\}} & \text{si } x > 0 \\ 0 & \text{en otro caso} \end{cases}$$

Nota: Como los máximos en general son valores grandes, importa particularmente observar el comportamiento de estas distribuciones para x tendiendo a infinito. El límite es 1 como en toda distribución. Pero *VA MAS RAPIDO* a 1 la Weibull, luego la Gumbel y luego la Fréchet. Esto es indicio que la Fréchet modela datos *más extremos*, máximos de datos de colas más pesadas que la Gumbel y ésta que la Weibull. Más adelante veremos esto más precisamente. En la Fréchet, la velocidad de convergencia a 1 crece al aumentar el orden. En cambio en la Weibull el orden afecta la velocidad con que va a 0 cuando x tiende a menos infinito, que crece cuanto mayor el orden. Esto quedará más claro con el Teorema 1 del curso. La visualización de las densidades de cada tipo quizás ayude a comprender mejor los pesos relativos de las colas.



A estas versiones standard se las puede extender agregando un parámetro de recentramiento (μ) y un parámetro de escala (β).

Se dice que X tiene distribución:

- **Gumbel** : $\Lambda^{(\mu,\beta)}$ si $X = \mu + \beta Y$, donde Y tiene distribución Λ .
- **Weibull**: $\Psi^{(\mu,\beta)}$ si $X = \mu + \beta Y$, donde Y tiene distribución Ψ_α .
- **Fréchet**: $\Phi^{(\mu,\beta)}$ si $X = \mu + \beta Y$, donde Y tiene distribución Φ_α .

En general, es en este sentido que diremos que una variable es Gumbel, Weibull o Fréchet (incluyendo recentramiento y reescalamiento), pero en cálculos donde los parámetros μ y β no sean relevantes, por simplicidad, usaremos las versiones standard.

El siguiente teorema vincula las distribuciones extremas en sus formatos standard y resulta de gran utilidad práctica sobre todo al hacer tests de ajustes, etc.

Teorema 1.1 (Relaciones entre las versiones standard de las distribuciones extremas). X tiene distribución $\Phi_\alpha \Leftrightarrow (-1/X)$ tiene distribución $\Psi_\alpha \Leftrightarrow \log(X^\alpha)$ tiene distribución Λ .

Nota: en otros contextos de la Estadística (en particular en algunas rutinas del R), se le llama Weibull a una variable que corresponde a $-X$, con X Weibull como definimos nosotros.

Observación 5: Recordamos que la función Gamma (Γ), que extiende a la función factorial ($\Gamma(n) = n - 1! \quad \forall n$ natural) definida por

$$\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt \quad (1.6)$$

es una función disponible tanto en el software R como en planillas de cálculo, etc.

Teorema 1.2 (Algunos datos de las distribuciones extremas). *Tres partes:*

Parte 1

Si X tiene distribución $\Lambda^{(\mu, \beta)}$ entonces tiene:

- a) **Esperanza:** $E(X) = \mu + \beta\gamma$, donde γ es la constante de Euler-Mascheroni, cuyo valor aproximado es 0.5772156649.
- b) **Moda:** $\text{moda}(X) = \mu$
- c) **Mediana:** $\text{med}(X) = \mu - \beta \log(\log 2) \approx \mu - 0.36651\beta$
- d) **Desviación estándar:** $\sigma(X) = \frac{\beta\pi}{\sqrt{6}} \approx 1.2825\beta$
- e) Si $X^+ = \max(X, 0)$, entonces $E(X + k)$ es finito para todo valor de k natural
- f) Para simular computacionalmente X , se puede tomar U uniforme en $(0, 1)$ y hacer $X = \mu - \beta \log(-\log U)$.

Parte 2

Si X tiene distribución $\Psi^{(\mu, \beta)}$ entonces tiene:

- a) $E(X) = \mu - \beta\Gamma(1 + 1/\alpha)$
- b)
$$\text{moda}(X) = \begin{cases} \mu & \text{si } \alpha \leq 1 \\ \mu - \beta \left\{ \frac{(\alpha-1)}{\alpha} \right\}^{1/\alpha} & \text{si } \alpha > 1 \end{cases}$$
- c) $\text{med}(X) = \mu - \beta(\log 2)^{\frac{1}{\alpha}}$
- d) $\sigma(X) = \beta \left\{ \Gamma\left(1 + \frac{2}{\alpha}\right) - \Gamma\left(1 + \frac{1}{\alpha}\right)^2 \right\}^{1/2}$.

Parte 3

Si X tiene distribución $\Phi_{\alpha}^{(\mu, \beta)}$ entonces tiene:

a)

$$E(x) = \begin{cases} \mu + \beta \Gamma\left(1 - \frac{1}{\alpha}\right) & \text{si } \alpha > 1 \\ \infty & \text{en otro caso} \end{cases}$$

b) $\text{moda}(X) = \mu + \beta \left\{ \frac{\alpha}{1+\alpha} \right\}^{1/\alpha}$

c) $\text{med}(X) = \mu + \beta (\log 2)^{(-1/\alpha)}$

d)

$$\sigma(x) = \begin{cases} \mu + \left| \Gamma\left(1 - \frac{2}{\alpha}\right) - \Gamma\left(1 - \frac{1}{\alpha}\right) \right| & \text{si } \alpha > 2 \\ \infty & \text{si } 1 < \alpha \leq 2 \end{cases}$$

Observación 6: El ítem e) de la Parte 1 es trivialmente cierto para Weibull y tomando en cuenta el ítem a) de la Parte 3, es claramente falso para Fréchet.

Observación 7: El ítem f) de la Parte 1 en conjunto con el teorema 1.1 brinda fórmulas sencillas para simular computacionalmente distribuciones Weibull o Fréchet.

Observación 8: Se generaron mil números aleatorios y aplicando el ítem f) de la Parte 1: se simuló mil variables Gumbel standard *iid*, calculándose su promedio, su desviación standard empírica y su mediana empírica.

```
# Fijar semilla para reproducibilidad
set.seed(123)

# Definir parámetros
mu <- 0          # Centro
beta <- 1         # Escala
gamma <- 0.5772156649 # Constante de Euler-Mascheroni

# Número de simulaciones
n <- 1000

# Generar 1000 valores de una variable uniforme en (0,1)
U <- runif(n)

# Simular la variable Gumbel con parámetros (mu, beta)
X_gumbel <- mu - beta * log(-log(U))

# Calcular estadísticas
esperanza <- mu + beta * gamma
```

```

moda <- mu
mediana_teorica <- mu - beta * log(log(2))
desviacion_std_teorica <- beta * pi / sqrt(6)

# Calcular estadísticas empíricas
promedio_empirico <- mean(X_gumbel)
desviacion_std_empirica <- sd(X_gumbel)
mediana_empirica <- median(X_gumbel)

```

Los resultados fueron los siguientes:

```

## ----- Resultados teóricos: -----

## Esperanza teórica: 0.5772157

## Moda teórica: 0

## Mediana teórica: 0.3665129

## Desviación estándar teórica: 1.28255

## ----- Resultados empíricos (simulación con n = 1000 ): -----

## Promedio empírico: 0.5610296

## Desviación estándar empírica: 1.261928

## Mediana empírica: 0.3376409

```

Observar que los resultados empíricos están cerca del valor esperado, desvío standard y mediana de la Gumbel standard.

A continuación presentaremos el Teorema medular de esta primera parte, expresado de la manera más llana posible. Veremos posteriormente algunos detalles con más cuidado. En particular, veremos que la continuidad de la distribución F no es una hipótesis real (ni es necesaria ni es suficiente, por eso la entrecomillamos), pero ayuda a visualizar que no vale el teorema para toda distribución F , así como veremos con cierto detalle más adelante...

Teorema 3: de Fischer-Tippet-Gnedenko (FTG)

Si X_1, \dots, X_n es *iid* con distribución F ‘continua’, llamamos F_n^* a la distribución de $\max(X_1, \dots, X_n)$ y n es grande, entonces existen μ real y $\beta > 0$ tales que alguna de las siguientes tres afirmaciones es correcta:

- a) F_n^* se puede aproximar por la distribución de $\mu + \beta Y$, con Y variable con distribución Λ .
- b) Existe $\alpha > 0$ tal que F_n^* se puede aproximar por la distribución de $\mu + \beta Y$ con Y variable con distribución Φ_α .
- c) Existe $\alpha > 0$ tal que F_n^* se puede aproximar por la distribución de $\mu + \beta Y$ con Y variable con distribución Φ_α .

Lo anterior equivale a decir que la distribución del máximo de datos *continuos* e *iid*, si n es grande, puede aproximarse por una Gumbel, una Fréchet o una Weibull.

Observación 9: Como veremos con cierto detalle, cuál de las tres aproximaciones es la válida depende de cómo sea la distribución F .

Por ejemplo, veremos que:

- Si F es normal o exponencial, se aplica a F_n^* la aproximación por una Gumbel .
- Si F es uniforme, vale para F_n^* la aproximación por una Weibull.
- Si F es Cauchy, la aproximación válida para F_n^* es por una Fréchet.

Más precisamente, cuál de las tres aproximaciones es la aplicable depende de la cola de F^1 .

En concreto, Weibull aparece cuando F es la distribución de una variable acotada por arriba (como la Uniforme), Gumbel para distribuciones de variables no acotadas por arriba pero con colas muy livianas (caso Exponencial y Normal) y Fréchet para colas pesadas (caso Cauchy). Finalmente, si bien aclaramos que la hipótesis de continuidad de F no es esencial, veremos que si F es la distribución Binomial o Poisson, por mencionar dos ejemplos muy conocidos y sencillos, NO se puede aplicar ninguna de las tres aproximaciones anteriores.

Observación 10. Como consecuencia del *FTG* si se tienen datos de máximos, las distribuciones extremas son “candidatas” razonables para proponer en un ajuste. Sin embargo no debe pensarse que siempre se va a lograr ajustar a una de las tres distribuciones extremas, ya que hay al menos dos causas evidentes que podrían desbaratar la aplicación del *FTG*:

- 1) Que la cantidad de registros que se consideran al calcular cada máximo no sea suficientemente grande.
- 2) Que los registros que se consideran al calcular cada máximo no sean *iid*².

¹Los valores de $F(t)$ para valores grandes de t .

²Al final del capítulo 2 se verá que esto puede subsanarse con versiones más generales del *FTG*.

Por consiguiente el *FTG* alienta a intentar ajustar datos extremales a una de las tres distribuciones extremales, pero no siempre un tal ajuste dará un resultado afirmativo.

Ejemplo 1. Veamos un ejemplo de ajuste. Los siguientes datos corresponden a los valores, en 80 puntos geográficos distintos de la región parisina, del máximo estival del contaminante atmosférico O_3 (no perceptible sensorialmente y con impacto sanitario serio). Cada dato es el máximo registro en cada sensor a lo largo de todo un verano; el contaminante se mide diariamente, por lo cual, cada uno de nuestros 80 datos es el máximo de unas 100 lecturas diarias.

```
## [1] "Primeros 6 datos:"
```

```
##      X_i
## 1 430.30
## 2 115.70
## 3   4.48
## 4  26.95
## 5  72.27
## 6 206.40
```

Los valores se miden en unidades de referencia standarizadas que, en particular, permiten comparar las medidas de lugares diferentes, independientemente de variables relevantes como altura e incidencia solar, por trabajo previo de calibración.

El objetivo del estudio en esta etapa es conocer la distribución de estos datos y en particular estimar la probabilidad de que el máximo estival en los 80 puntos supere el valor 50 (correspondiente a existencia de riesgo moderado).

Veamos los datos que tenemos:

```
## [1] "Cálculo de estadísticos básicos"
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      4.48   23.44   52.77  183.93  166.82 1675.00
```

Como la mayoría de tests de ajustes suponen datos *iid*, realizaremos dos tests de aleatoriedad³:

- Runs test (Up & Down)
- Spearman correlation of ranks

³En inglés es *randomness*.

Para realizar el ajuste utilizaremos el test χ^2 de ajuste⁴. Este test requiere elegir una partición más o menos arbitraria de la recta real en intervalos; sin embargo es importante que en cada intervalo caiga una cantidad suficiente de datos de la muestra; en este caso hemos tomado como extremos de los intervalos los quintiles empíricos de nuestra muestra.

Una aclaración mucho más importante es que este test requiere estimar parámetros por el método de Máxima Verosimilitud Categórica, que da resultado distintos al método de Máxima Verosimilitud a secas⁵.

```
##
##  Runs Test
##
## data:  as.factor(runs_sequence)
## Standard Normal = 2.4678, p-value = 0.01359
## alternative hypothesis: two.sided

##
##  Spearman's rank correlation rho
##
## data:  data$X_i and seq_along(data$X_i)
## S = 85949, p-value = 0.9483
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
##          rho
## -0.007372289
```


Como cada dato de los 80 que disponemos es un máximo de un centenar de observaciones, intentaremos ajustarlos a una distribución extremal sabiendo que no necesariamente tendremos éxito.

Observemos en particular que lo que pasamos por dos tests de aleatoriedad son los 80 máximos, pero no el centenar de lecturas que forman cada uno de los 80 máximos (ni siquiera tenemos esos datos originales).

Dado que visualmente se aprecian valores muy apartados, se presume una distribución de colas pesadas y por ese motivo se intenta un ajuste a una Fréchet.

⁴Una excelente referencia para la temática de los test χ^2 de ajuste es la introducción del trabajo Pearsonian Tests and Modifications (Jorge Graneri, CMAT, Facultad de Ciencias, 2002).

⁵Este hecho es frecuentemente ignorado y presentado erróneamente en los textos y cursos básicos de Estadística.



```
# Parámetros del libro
loc_libro <- -6.5      #
scale_libro <- 44      #
shape_libro <- 1.04    # (parámetro de forma positivo, Fréchet)

# Cálculo de la probabilidad de exceder el valor 50
prob_excede_50 <- 1 - pgev(50, loc = loc_libro, scale = scale_libro, shape = shape_libro)

# Mostrar la probabilidad de excedencia
print(paste("Probabilidad de excedencia del nivel 50:", round(prob_excede_50, 4)))

## [1] "Probabilidad de excedencia del nivel 50: 0.3575"

# Proporción empírica de excedencia del nivel 50
prop_empirica <- mean(data$X_i > 50)
print(paste("Proporción empírica de excedencia del nivel 50:", round(prop_empirica, 4)))

## [1] "Proporción empírica de excedencia del nivel 50: 0.5125"

# Intervalo de confianza para la proporción empírica
prop_ci <- prop.test(sum(data$X_i > 50), length(data$X_i))$conf.int
print(paste("Intervalo de confianza al 95%:", round(prop_ci[1], 3), "-", round(prop_ci[2], 3)))

## [1] "Intervalo de confianza al 95%: 0.399 - 0.625"
```

```
print(paste("Probabilidad de excedencia del nivel 50:", round(prob_excede_50, 4)))
```

```
## [1] "Probabilidad de excedencia del nivel 50: 0.3575"
```

```
# Parámetros del libro
loc_libro <- -6.5      #
scale_libro <- 44      #
shape_libro <- 1.04    # (parámetro de forma positivo, Fréchet)

# Cálculo de la probabilidad de exceder el valor 50
prob_excede_50 <- 1 - pgev(50, loc = loc_libro, scale = scale_libro, shape = shape_libro)
print(paste("Probabilidad de excedencia del nivel 50:", round(prob_excede_50, 4)))
```

```
## [1] "Probabilidad de excedencia del nivel 50: 0.3575"
```

```
# Parámetros del libro
loc_libro <- -6.5      #
scale_libro <- 44      #
shape_libro <- 1.04    # (parámetro de forma positivo, Fréchet)

# Definir intervalos usando los quintiles empíricos
breaks <- quantile(data$X_i, probs = seq(0, 1, length.out = 6)) # 5 intervalos

# Calcular las frecuencias observadas en cada intervalo
observed_counts <- hist(data$X_i, breaks = breaks, plot = FALSE)$counts

# Calcular las probabilidades teóricas en cada intervalo usando la distribución Fréchet
probs <- diff(pgev(breaks, loc = loc_libro, scale = scale_libro, shape = shape_libro))

# Convertir probabilidades en frecuencias esperadas
expected_counts <- probs * length(data$X_i)

# Realizar el test de ajuste Chi-cuadrado
chi_sq_test <- chisq.test(observed_counts, p = probs, rescale.p = TRUE)

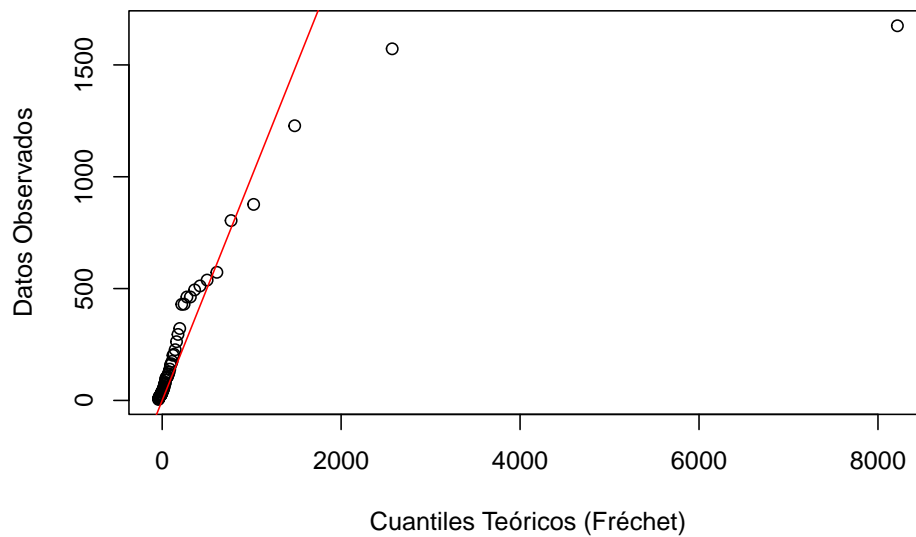

# Mostrar los resultados del test
print("Resultados del test Chi-cuadrado con los parámetros del libro:")
```

```
## [1] "Resultados del test Chi-cuadrado con los parámetros del libro:"
```

```
print(chi_sq_test)
```



```
##
## Chi-squared test for given probabilities
##
## data:  observed_counts
## X-squared = 4.3938, df = 4, p-value = 0.3553
```

Q-Q Plot para la Distribución Fréchet Ajustada**Histograma y Densidad Ajustada (Fréchet)**

Observación 10. Una distribución H se dice degenerada si $H(t) = 0$ ó 1 para

todo valor de t . Representan a variables que no son tales, si la distribución de X es degenerada, entonces X es una constante, y no tiene sentido hacer estadística sobre X , por lo tanto sólo tienen interés para nosotros las distribuciones no-degeneradas.

1.3 Distribución Extremal Asintótica

Si X_1, \dots, X_n es iid con distribución F diremos que H no-degenerada es la Distribución Extremal Asintótica (DEA) de F^6 , si existen dos sucesiones de números reales, d_n y $c_n > 0$, tales que la distribución de

$$\frac{\max(X_1, \dots, X_n) - d_n}{c_n} \text{ tiende a } H \text{ cuando } n \text{ tiende a infinito.} \quad (1.7)$$

1.4 Supremo esencial de una variable aleatoria o distribución

Si X tiene distribución F , se llama M_X al supremo esencial de X o, indistintamente, supremo esencial de F (denotado M_F) a

$$M_X = M_F = \sup\{t / F(t) < 1\} \quad (1.8)$$

Observación 11.

- Si F es $U(a, b)$, $M_F = b$.
- Si F es $Bin(m, p)$, $M_F = m$.
- Si F es Normal, Exponencial, Cauchy o Poisson entonces M_F es infinito.

Teorema 4: Si X_1, \dots, X_n iid con distribución F cualquiera, entonces, para $n \rightarrow \infty$,

$$X_n^* = \max(X_1, \dots, X_n) \rightarrow M_F \quad (1.9)$$

Observación 12. El resultado anterior vale incluso si M_F es infinito, pero si M_F es finito, como $X_n^* - M_F$ tiende a cero, por analogía con el Teorema Central del Límite para promedios, buscaríamos una sucesión $c_n > 0$ y que tienda a cero de modo tal que $(X_n^* - M_F)/c_n$ tienda a una distribución no-degenerada y de allí surge buscar la DEA.

⁶De manera equivalente, que F tiene DEA H .

Teorema 5: Si F es una distribución con M_F finito, y para X con distribución F se cumple que

$$P(X = M_F) > 0 \quad (1.10)$$

entonces F no admite DEA.

Observación 13. Si F es $\text{Bin}(m, p) \Rightarrow M_F = m$. Si X tiene distribución F , entonces $P(X = M_F) = P(X = m) = p^m > 0$, así que la distribución $\text{Bin}(m, p)$ NO admite DEA, no se puede aproximar la distribución del máximo de una muestra iid de variables $\text{Bin}(m, p)$.

El Teorema anterior es un caso particular del próximo.

Teorema 6: Si F es una distribución con M_F finito o infinito que admite DEA, y X tiene distribución F , entonces el límite cuando t tiende a M_F por izquierda de

$$P(X > t)/P(X \leq t) \quad (1.11)$$

debe ser 1.

Observación 13. Si F es una distribución de Poisson de parámetro $\lambda > 0$, M_F es infinito. Si k es un natural, entonces

$$P(X > t)/P(X \leq t) = P(X \leq k+1)/P(X \leq k) \quad (1.12)$$

$$= 1 - \{P(X = k)/P(X \leq k)\} \approx 1 - (1 - \lambda/k) \quad (1.13)$$

que tiende a 0 cuando k tiende a infinito, por lo cual F NO admite DEA, o sea que no se puede aproximar el máximo de una sucesión iid de variables de Poisson.

Observación 14. El Teorema 6 brinda una condición NECESARIA pero NO SUFICIENTE para DEA. Un ejemplo de ello lo aportó Von Mises, mostrando que la distribución

$$F(x) = 1 - e^{(-x - \sin(x))} \quad (1.14)$$

cumple con la condición del Teorema 6 pero no admite DEA. El tema será cerrado al estudiar los dominios de atracción maximal, en breve.

Veamos ahora ejemplos donde la DEA resulta aplicable y que ratifican algunos hechos que anticipáramos.

Observación 15. Si F es $U(0, 1)$ y consideramos X_1, \dots, X_n iid con distribución F , resulta que la distribución de $n(X_n^* - 1)$ tiende a Ψ_1 por lo cual la distribución uniforme tiene DEA Weibull.

Observación 16. Si F es Exponencial de parámetro 1 y consideramos X_1, \dots, X_n iid con distribución F , se tiene que la distribución de $X_n^* - \log n$ tiende a Λ por lo cual la distribución exponencial tiene DEA Gumbel.

Observación 17. Si F es $N(0, 1)$ y consideramos X_1, \dots, X_n iid con distribución F , definimos la función continua y estrictamente decreciente (para $u > 0$)

$$g(u) = \frac{e^{-u^2/4\pi}}{u}. \quad (1.15)$$

Como $\lim_{u \rightarrow 0} g(u) \rightarrow \infty$ y $\lim_{u \rightarrow \infty} g(u) \rightarrow 0$, para todo natural n existe un único valor u_n tal que

$$g(u_n) = \frac{1}{n} \quad (1.16)$$

y resulta que $\frac{u_n}{\sqrt{2\pi(X_n^* - u_n/\sqrt{2\pi})}} \rightarrow \Lambda$, por lo cual la distribución normal tiene DEA Gumbel.

Observación 18. Si F es Cauchy standard que se expresa como $C(0, 1)$ y consideramos X_1, \dots, X_n iid con distribución F , se tiene que la distribución de $\pi X_n^*/n$ tiende a F_1 por lo cual la distribución Cauchy tiene DEA Fréchet.

Los ejemplos anteriores no son sorprendentes, en el sentido que aunque presentamos FTG en una versión simplificada, dicho teorema sugiere que cuando F admite DEA, la distribución H deberá ser una distribución extremal. De hecho FTG resulta de combinar dos teoremas, basadas en una nueva definición, la de distribución **max-estable**.

1.5 Distribución max-estables

Si dada F distribución, X con distribución F , k natural arbitrario y X_1, \dots, X_k iid con distribución F , existen reales a_k, b_k tales que $\max(X_1, \dots, X_k)$ tiene la misma distribución que $a_k X + b_k$, F se dice max-estable.

El Teorema FTG resulta de superponer los dos siguientes teoremas.

Teorema 7:

- a) Si F admite DEA H , entonces H es max-estable.
- b) Si H es max-estable, es la DEA de sí misma.

Teorema 8:

Una distribución es max-estable si y solo si es extremal: Gumbel, Weibull, Fréchet.

El Teorema 7 es bastante intuitivo y análogo a los teoremas de Lévy sobre distribuciones estables en aproximaciones asintóticas de las distribuciones de sumas. Para el Teorema 8 haremos enseguida un ejercicio sencillo que nos ayudará a hacerlo creíble.

Luego precisaremos, para terminar con esta parte, cómo son las distribuciones que tienen por DEA cada uno de los tres tipos de distribuciones extremales. Para eso precisamos recordar algunas definiciones, como la siguiente.

Observación 19. Si F y G son dos distribuciones, tienen colas equivalentes si $M_F = M_G$ y cuando t tiende a M_F por izquierda, $(1 - F(t))/(1 - G(t))$ tiende a un valor $c > 0$.

Recordando ahora cómo se calcula la distribución del máximo de dos variables independientes, es muy sencillo calcular la distribución del $\max\{X, Y\}$, cuando X e Y son independientes y cada una de ellas es una distribución extremal. Se tiene el siguiente resultado.

X	Y	$\max(X, Y)$
Weibull	Weibull	Weibull
Weibull	Gumbel	Cola equivalente Gumbel
Weibull	Fréchet	Fréchet
Gumbel	Weibull	Cola equivalente Gumbel
Gumbel	Gumbel	Gumbel
Gumbel	Fréchet	Cola equivalente Fréchet
Fréchet	Weibull	Fréchet
Fréchet	Gumbel	Cola equivalente Fréchet
Fréchet	Fréchet	Fréchet

■ Las extremales son max-estables: tomar máximos de dos del mismo tipo queda en el mismo tipo.

■ Gumbel es más pesada que Weibull. En la cola, que es lo que cuenta para máximos, prima Gumbel.

■ Fréchet es más pesada que Gumbel y mucho más pesada que Weibull.

1.5.1 Ejemplos de libro

Ejemplos de Coles et al. [2001] con el paquete ? :

1.5.1.1 POT

Considerando la Figura 1.1, podemos definir un evento como extremo si supera un cierto nivel alto, quizás una precipitación diaria de 30 *mm* en este caso.




Figura 1.1: Acumulaciones diarias de lluvia en una ubicación en el suroeste de Inglaterra registradas durante el período 1914-1962.

Entonces, los valores extremos son ahora aquellas observaciones que superan un cierto umbral alto (Coles et al. [2001]).

Capítulo 2

Un primer enfoque de datos no *iid*

2.1 Análisis de series temporales

2.2 Pruebas de raíz unitaria y tendencia

2.2.1 Concepto de Estacionariedad

```
head(portpirie)
```

```
## [1] 4.03 3.83 3.65 3.88 4.01 4.08
```

La figura 2.1 muestra los niveles máximos anuales del nivel del mar registrados en Port Pirie, una localidad justo al norte de Adelaida, Australia del Sur, durante el período 1923-1987. A partir de estos datos, puede ser necesario estimar el nivel máximo del mar que probablemente ocurra en la región en los próximos 100 o 1000 años. Esto plantea una cuestión importante: ¿cómo podemos estimar los niveles que pueden ocurrir en los próximos 1000 años sin conocer, por ejemplo, los cambios climáticos que podrían suceder?

No hay evidencia contundente en la figura que sugiera que el patrón de variación en los niveles del mar haya cambiado durante el período de observación, pero dicha estabilidad podría no persistir en el futuro. Esta advertencia es crucial: aunque la teoría de valores extremos ha adoptado terminología como el “nivel de retorno a 1000 años”, que corresponde al nivel que se espera que sea excedido exactamente una vez en los próximos 1000 años, esto solo tiene sentido bajo




Figura 2.1: Niveles máximos anuales del nivel del mar registrados en Port Pirie.

el supuesto de estabilidad (o estacionariedad) en el proceso subyacente. Es más realista hablar en términos de niveles que, bajo las condiciones actuales, ocurrirán en un año determinado con una baja probabilidad (Coles et al. [2001]).

2.2.1.1 Ejemplo en Finanzas

Las técnicas de valores extremos han ganado popularidad en aplicaciones financieras. Esto no es sorprendente: la solvencia financiera de una inversión probablemente esté determinada por cambios extremos en las condiciones del mercado en lugar de cambios típicos. Sin embargo, la compleja estructura estocástica de los mercados financieros implica que la aplicación ingenua de técnicas de valores extremos puede ser engañosa (Coles et al. [2001]).

```
data(dowjones)
dowjones$LogDiff <- c(NA, diff(log(dowjones$Index)))
```

```
head(dowjones)
```

```
##           Date      Index      LogDiff
## 1 1995-09-11 02:00:00 4704.94          NA
## 2 1995-09-12 02:00:00 4747.21  0.0089440565
## 3 1995-09-13 02:00:00 4765.52  0.0038495832
## 4 1995-09-14 02:00:00 4801.80  0.0075841874
## 5 1995-09-15 02:00:00 4797.57 -0.0008813079
## 6 1995-09-18 02:00:00 4780.41 -0.0035832228
```





Figura 2.2: Panel a) Precios de cierre diario del índice Dow Jones. Panel b) Rendimientos diarios del índice Dow Jones (en logaritmos).

La Fig.2.2 muestra los precios de cierre diario del índice Dow Jones durante un período de 5 años. Evidentemente, el nivel del proceso ha cambiado drásticamente a lo largo del período observado, y las cuestiones sobre los valores extremos del comportamiento diario quedan eclipsadas por la variación temporal a largo plazo en la serie. Varios estudios empíricos sobre series de este tipo han indicado que se puede obtener una aproximación a la estacionariedad tomando los logaritmos de los cocientes de observaciones sucesivas, lo que se conoce como los retornos logarítmicos diarios. El panel b) de la Fig. 2.2 sugiere una transformación razonablemente exitosa hacia la estacionariedad. El análisis de las propiedades de valores extremos de dichas series transformadas puede proporcionar a los analistas financieros información clave sobre el mercado (Coles et al. [2001]).

Capítulo 3

Parts

You can add parts to organize one or more book chapters together. Parts can be inserted at the top of an .Rmd file, before the first-level chapter heading in that same file.

Add a numbered part: `# (PART) Act one {-}` (followed by `# A chapter`)

Add an unnumbered part: `# (PART*) Act one {-}` (followed by `# A chapter`)

Add an appendix as a special kind of un-numbered part: `# (APPENDIX) Other stuff {-}` (followed by `# A chapter`). Chapters in an appendix are prepended with letters instead of numbers.

Capítulo 4

Footnotes and citations

4.1 Footnotes

Footnotes are put inside the square brackets after a caret `^[]`. Like this one ¹.

4.2 Citations

Reference items in your bibliography file(s) using `@key`.

For example, we are using the **bookdown** package [Xie, 2025] (check out the last code chunk in `index.Rmd` to see how this citation key was added) in this sample book, which was built on top of R Markdown and **knitr** [Xie, 2015] (this citation was added manually in an external file `book.bib`). Note that the `.bib` files need to be listed in the `index.Rmd` with the YAML `bibliography` key.

The RStudio Visual Markdown Editor can also make it easier to insert citations: <https://rstudio.github.io/visual-markdown-editing/#/citations>

¹This is a footnote.

Capítulo 5

Blocks

5.1 Equations

Here is an equation.

$$f(k) = \binom{n}{k} p^k (1-p)^{n-k} \quad (5.1)$$

You may refer to using `\@ref{eq:binom}`, like see Equation (5.1).

5.2 Theorems and proofs

Labeled theorems can be referenced in text using `\@ref{thm:tri}`, for example, check out this smart theorem 5.1.

Teorema 5.1. *For a right triangle, if c denotes the length of the hypotenuse and a and b denote the lengths of the **other** two sides, we have*

$$a^2 + b^2 = c^2$$

Read more here <https://bookdown.org/yihui/bookdown/markdown-extensions-by-bookdown.html>.

5.3 Callout blocks

The R Markdown Cookbook provides more help on how to use custom blocks to design your own callouts: <https://bookdown.org/yihui/rmarkdown-cookbook/custom-blocks.html>

5.4 Referencias cruzadas

There are two steps to cross-reference any heading:

1. Label the heading: `# Hello world {#nice-label}`.
 - Leave the label off if you like the automated heading generated based on your heading title: for example, `# Hello world = # Hello world {#hello-world}`.
 - To label an un-numbered heading, use: `# Hello world {-#nice-label}` or `{# Hello world .unnumbered}`.
2. Next, reference the labeled heading anywhere in the text using `\@ref(nice-label)`; for example, please see Chapter 2.
 - If you prefer text as the link instead of a numbered reference use: any text you want can go here.

Figures and tables *with captions* can also be cross-referenced from elsewhere in your book using `\@ref(fig:chunk-label)` and `\@ref(tab:chunk-label)`, respectively.

See Figure 5.1.

```
par(mar = c(4, 4, .1, .1))
plot(pressure, type = 'b', pch = 19)
```

Don't miss Table 5.1.

```
knitr::kable(
  head(pressure, 10), caption = 'Here is a nice table!',
  booktabs = TRUE
)
```





Figura 5.1: Here is a nice figure!

Tabla 5.1: Here is a nice table!

temperature	pressure
0	0.0002
20	0.0012
40	0.0060
60	0.0300
80	0.0900
100	0.2700
120	0.7500
140	1.8500
160	4.2000
180	8.8000

Capítulo 6

Sharing your book

6.1 Publishing

HTML books can be published online, see: <https://bookdown.org/yihui/bookdown/publishing.html>

6.2 404 pages

By default, users will be directed to a 404 page if they try to access a webpage that cannot be found. If you'd like to customize your 404 page instead of using the default, you may add either a `_404.Rmd` or `_404.md` file to your project root and use code and/or Markdown syntax.

6.3 Metadata for sharing

Bookdown HTML books will provide HTML metadata for social sharing on platforms like Twitter, Facebook, and LinkedIn, using information you provide in the `index.Rmd` YAML. To setup, set the `url` for your book and the path to your `cover-image` file. Your book's `title` and `description` are also used.

This `gitbook` uses the same social sharing data across all chapters in your book—all links shared will look the same.

Specify your book's source repository on GitHub using the `edit` key under the configuration options in the `_output.yml` file, which allows users to suggest an edit by linking to a chapter's source file.

Read more about the features of this output format here:

<https://pkgs.rstudio.com/bookdown/reference/gitbook.html>

Or use:

```
?bookdown::gitbook
```

Bibliografía

Stuart Coles, Joanna Bawa, Lesley Trenner, and Pat Dorazio. *An introduction to statistical modeling of extreme values*, volume 208. Springer, 2001.

Yihui Xie. *Dynamic Documents with R and knitr*. Chapman and Hall/CRC, Boca Raton, Florida, 2nd edition, 2015. URL <http://yihui.org/knitr/>. ISBN 978-1498716963.

Yihui Xie. *bookdown: Authoring Books and Technical Documents with R Markdown*, 2025. URL <https://github.com/rstudio/bookdown>. R package version 0.42.